

Analiza sprzedaży sklepu internetowego

Narzędzia: MySQL, DBeaver, Excel (Pivot Tables, Power Query), PowerPoint, Microsoft Word.

Zbiór danych: Online Retail II (Year 2010-2011)

Źródło: [Kaggle](#).

Projekt dotyczy analizy transakcji sprzedażowych sklepu internetowego na podstawie danych z pliku online_retail_II.xlsx pobranego z platformy Kaggle. W projekcie wykorzystano arkusz Year 2010–2011, zawierający dane internetowego sprzedawcy z Wielkiej Brytanii. Zbiór danych obejmuje numery faktur, kody i opisy produktów, ilości, daty transakcji, ceny, identyfikatory klientów oraz informacje o krajach. Celem projektu było oczyszczenie danych w SQL, obliczenie kluczowych wskaźników biznesowych oraz przygotowanie dashboardu w Excelu, który w przejrzysty sposób prezentuje najważniejsze wyniki analizy i wspiera raportowanie.

1. Czyszczenie danych w SQL

Dane oczyszczono w SQL, aby przygotować je do dalszej analizy. Usunięto anulowane transakcje rozpoznawane po numerach faktur rozpoczynających się od litery „C”, a także rekordy z niedodatnią ilością lub ceną. Następnie utworzono oczyszczoną tabelę i obliczono przychód dla każdego wiersza jako iloczyn kolumn Quantity i Price.

Główne zapytania wykorzystane w projekcie:

- i. Zapytanie czyszczące:

```
CREATE TABLE online_retail_clean AS
SELECT
    Invoice, StockCode, Description,
    Quantity, InvoiceDate, Price,
    `Customer ID`,
    Country,
    Quantity * Price AS revenue
FROM online_retail_II
WHERE Invoice NOT LIKE 'C%'
    AND Quantity > 0
    AND Price > 0;
```

- ii. Zapytanie weryfikujące:

```
SELECT COUNT(*) AS clean_rows
FROM online_retail_clean;

SELECT Invoice
FROM online_retail_clean
WHERE Invoice LIKE 'C%'
LIMIT 10;

SELECT *
FROM online_retail_clean
WHERE InvoiceDate IS NULL
    OR TRIM(InvoiceDate) = '';
```

2. Obliczenie KPI

Po oczyszczeniu danych wyliczono kluczowe wskaźniki biznesowe opisujące wyniki sprzedaży. Na ich podstawie przygotowano zestawienie najważniejszych wartości, które następnie wykorzystano w dashboardzie w Excelu.

Zapytanie SQL:

```
SELECT
    ROUND(SUM(revenue), 2) AS total_revenue,
    SUM(Quantity) AS total_quantity_sold,
    COUNT(DISTINCT `Customer ID`) AS unique_customers,
    COUNT(DISTINCT Invoice) AS total_orders,
    ROUND(SUM(revenue) / COUNT(DISTINCT Invoice), 2) AS avg_order_value
FROM online_retail_clean;
```

Wyniki obliczeń w SQL:

	123 total_revenue	123 total_quantity_sold	123 unique_customers	123 total_orders	123 avg_order_value
1	10,666,702.54	5,588,377	4,338	19,960	534.4

Wyniki obliczeń w Excelu:

Total Revenue	Total Quantity Sold	Unique Customers	Total Orders	Average Order Value
£10,666,702.54	5,588,377	4,338	19,960	£534.40

3. Analiza czasowa

3.1) Monthly Revenue Trend

Porównanie miesięcznych przychodów pokazało, że sprzedaż nie była równomierna w całym badanym okresie. Najwyższy poziom przychodu odnotowano w listopadzie 2011 roku, co może wskazywać na wzrost popytu pod koniec roku.

Zapytanie SQL:

```
SELECT
    DATE_FORMAT(parsed_date, '%m/%Y') AS invoice_month,
    ROUND(SUM(revenue), 2) AS monthly_revenue
FROM (
    SELECT
        STR_TO_DATE(InvoiceDate, '%d/%m/%Y %H:%i') AS parsed_date,
        revenue
    FROM online_retail_clean
) t
GROUP BY DATE_FORMAT(parsed_date, '%m/%Y'), YEAR(parsed_date), MONTH(parsed_date)
ORDER BY YEAR(parsed_date), MONTH(parsed_date);
```

Wyniki obliczeń w SQL:

	Az invoice_month	I23 monthly_revenue
1	12/2010	823,746.14
2	01/2011	691,364.56
3	02/2011	523,631.89
4	03/2011	717,639.36
5	04/2011	537,808.62
6	05/2011	770,536.02
7	06/2011	761,739.9
8	07/2011	719,221.19
9	08/2011	759,138.38
10	09/2011	1,058,590.17
11	10/2011	1,154,979.3
12	11/2011	1,509,496.33
13	12/2011	638,810.68

Wyniki obliczeń w Excelu:

Row Labels	Sum of revenue
12/2010	823,746.14
01/2011	691,364.56
02/2011	523,631.89
03/2011	717,639.36
04/2011	537,808.62
05/2011	770,536.02
06/2011	761,739.90
07/2011	719,221.19
08/2011	759,138.38
09/2011	1,058,590.17
10/2011	1,154,979.30
11/2011	1,509,496.33
12/2011	638,810.68

3.2) Quantity Sold by Hour

Analiza godzinowa pokazała, że największa sprzedaż ilościowa przypadła na godziny od późnego rana do wczesnego popołudnia. Najwyższe wartości odnotowano około południa, natomiast w godzinach porannych i wieczornych sprzedawanych sztuk było wyraźnie mniej.

Zapytanie SQL:

```
SELECT
    DATE_FORMAT(parsed_date, '%H:00') AS invoice_hour,
    SUM(Quantity) AS total_quantity_sold
FROM (
    SELECT
        STR_TO_DATE(InvoiceDate, '%d/%m/%Y %H:%i') AS parsed_date,
        Quantity
    FROM online_retail_clean
) t
GROUP BY DATE_FORMAT(parsed_date, '%H:00'), HOUR(parsed_date)
ORDER BY HOUR(parsed_date);
```

Wyniki obliczeń w SQL:

	12 invoice_hour	123 total_quantity_sold
1	06:00	1
2	07:00	15,370
3	08:00	159,097
4	09:00	518,098
5	10:00	813,805
6	11:00	674,682
7	12:00	839,524
8	13:00	706,285
9	14:00	599,220
10	15:00	628,564
11	16:00	331,487
12	17:00	192,975
13	18:00	66,578
14	19:00	33,104
15	20:00	9,587

Wyniki obliczeń w Excelu:

Row Labels	Sum of Quantity
06:00	1
07:00	15,370
08:00	159,097
09:00	518,098
10:00	813,805
11:00	674,682
12:00	839,524
13:00	706,285
14:00	599,220
15:00	628,564
16:00	331,487
17:00	192,975
18:00	66,578
19:00	33,104
20:00	9,587

4. Analiza rynków i klientów

4.1) Revenue Share by Country

Analiza udziału przychodów według krajów została wykorzystana do wskazania najważniejszych rynków zagranicznych. Ponieważ analizowany sprzedawca działał w Wielkiej Brytanii, w tej części pominięto United Kingdom, aby skupić się na sprzedaży zagranicznej.

Zapytanie SQL:

```
WITH top_countries AS (
    SELECT
        Country,
        SUM(revenue) AS country_revenue
    FROM online_retail_clean
    WHERE Country <> 'United Kingdom'
    GROUP BY Country
    ORDER BY country_revenue DESC
    LIMIT 5
)
SELECT
    Country,
    ROUND(country_revenue / SUM(country_revenue) OVER () * 100, 2) AS revenue_share_percent
FROM top_countries
ORDER BY revenue_share_percent DESC;
```

Wyniki obliczeń w SQL:

	A-Z Country	123 revenue_share_percent
1	Netherlands	24.91
2	EIRE	24.73
3	Germany	19.97
4	France	18.3
5	Australia	12.09

Wyniki obliczeń w Excelu:

Countries	Sum of revenue
Netherlands	24.91%
EIRE	24.73%
Germany	19.97%
France	18.30%
Australia	12.09%

4.2) Top Customers by Revenue

Analiza klientów pozwoliła wskazać odbiorców generujących najwyższe przychody. Zestawienie pokazuje, że stosunkowo niewielka grupa klientów odpowiadała za istotną część całkowitej sprzedaży.

Zapytanie SQL:

```
SELECT
  `Customer ID`,
  ROUND(SUM(revenue), 2) AS total_revenue
FROM online_retail_clean
WHERE `Customer ID` IS NOT NULL
GROUP BY `Customer ID`
ORDER BY total_revenue DESC
LIMIT 5;
```

Wyniki obliczeń w SQL:

	123 Customer ID	123 total_revenue
1	14,646	280,206.02
2	18,102	259,657.3
3	17,450	194,550.79
4	16,446	168,472.5
5	14,911	143,825.06

Wyniki obliczeń w Excelu:

Customer ID	Sum of revenue
14646	280,206.02
18102	259,657.30
17450	194,550.79
16446	168,472.50
14911	143,825.06

5. Najlepiej i najslabiej sprzedające się produkty

5.1) Top 5 Products by Revenue

Analiza najlepiej sprzedających się produktów pozwoliła wskazać pozycje generujące najwyższe przychody. Zestawienie pokazuje, które produkty miały największy udział w sprzedaży i były kluczowe z punktu widzenia wyników finansowych.

Zapytanie SQL:

```
SELECT
    Description,
    ROUND(SUM(revenue), 2) AS total_revenue
FROM online_retail_clean
WHERE Description IS NOT NULL
    AND Description NOT IN ('DOTCOM POSTAGE', 'POSTAGE', 'Manual')
GROUP BY Description
ORDER BY total_revenue DESC
LIMIT 5;
```

Wyniki obliczeń w SQL:

	AZ Description	123 total_revenue
1	REGENCY CAKESTAND 3 TIER	174,484.74
2	PAPER CRAFT , LITTLE BIRDIE	168,469.6
3	WHITE HANGING HEART T-LIGHT HOLDER	106,292.77
4	PARTY BUNTING	99,504.33
5	JUMBO BAG RED RETROSPOT	94,340.05

Wyniki obliczeń w Excelu:

Row Labels	Sum of revenue
REGENCY CAKESTAND 3 TIER	174,484.74
PAPER CRAFT , LITTLE BIRDIE	168,469.60
WHITE HANGING HEART T-LIGHT HOLDER	106,292.77
PARTY BUNTING	99,504.33
JUMBO BAG RED RETROSPOT	94,340.05

5.2) Bottom 5 Products by Revenue

Analiza produktów o najniższych przychodach pozwoliła wskazać pozycje generujące marginalną sprzedaż. Zestawienie pokazuje, które produkty miały najmniejsze znaczenie dla całkowitych wyników sprzedaży i mogły mieć ograniczony wpływ na poziom przychodów.

Zapytanie SQL:

```
SELECT
    Description,
    ROUND(SUM(revenue), 2) AS total_revenue
FROM online_retail_clean
WHERE Description IS NOT NULL
    AND Description NOT IN ('DOTCOM POSTAGE', 'POSTAGE', 'Manual', 'PADS TO MATCH ALL CUSHIONS')
GROUP BY Description
ORDER BY total_revenue ASC
LIMIT 5;
```

Wyniki obliczeń w SQL:


	AZ Description	123 total_revenue
1	HEN HOUSE W CHICK IN NEST	0.42
2	SET 12 COLOURING PENCILS DOILEY	0.65
3	VINTAGE BLUE TINSEL REEL	0.84
4	PINK CRYSTAL GUITAR PHONE CHARM	0.85
5	HAPPY BIRTHDAY CARD TEDDY/CAKE	0.95

Wyniki obliczeń w Excelu:

Row Labels	Sum of revenue
HEN HOUSE W CHICK IN NEST	0.42
SET 12 COLOURING PENCILS DOILEY	0.65
VINTAGE BLUE TINSEL REEL	0.84
PINK CRYSTAL GUITAR PHONE CHARM	0.85
CAT WITH SUNGLASSES BLANK CARD	0.95
HAPPY BIRTHDAY CARD TEDDY/CAKE	0.95

6. Dashboard i wizualizacje

Ostatnim etapem projektu było przygotowanie dashboardu w Excelu, który prezentuje wyniki analizy w przejrzystej i użytecznej formie. Dashboard zawiera karty KPI, trend miesięcznych przychodów, sprzedaż ilościową według godzin, udział przychodów według krajów, klientów o najwyższych przychodach oraz najlepiej i najsłabiej sprzedające się produkty. Do jego przygotowania wykorzystano tabele przestawne, wykresy przestawne oraz dodatkowe formatowanie, co pozwoliło stworzyć czytelny raport o charakterze biznesowym.



Dashboard stanowi końcowy efekt projektu i prezentuje najważniejsze wyniki analizy w zwartej, czytelnej formie.